

Data Science Bootcamp

Comment ranker sur Google?
Tentative de retro-engineering
sur les annonces emploi

Caroline Heymes



"Accuracy: 0.71"

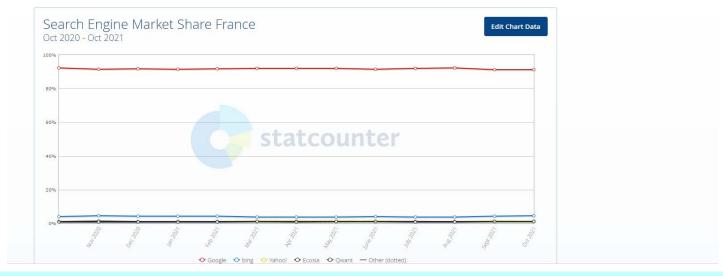


Contexte & enjeux



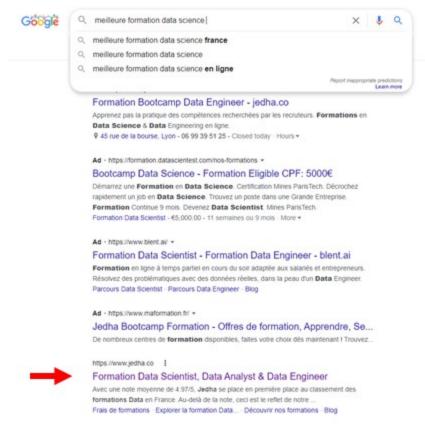
Moteurs de recherche : la domination de Google







Google : un moteur de réponses





0

Quels leviers jouent sur la serp?

- **Title**
 - Meta description (content, keyword, open_graph)
- Titres H1...Hn
- Texte
- Liens
 - Ancres des liens et des images
 - Page speed
- Qualité sémantique
 - Qualité du maillage interne
- Backlinks
- Mots clés qui correspondent à l'intention de recherche

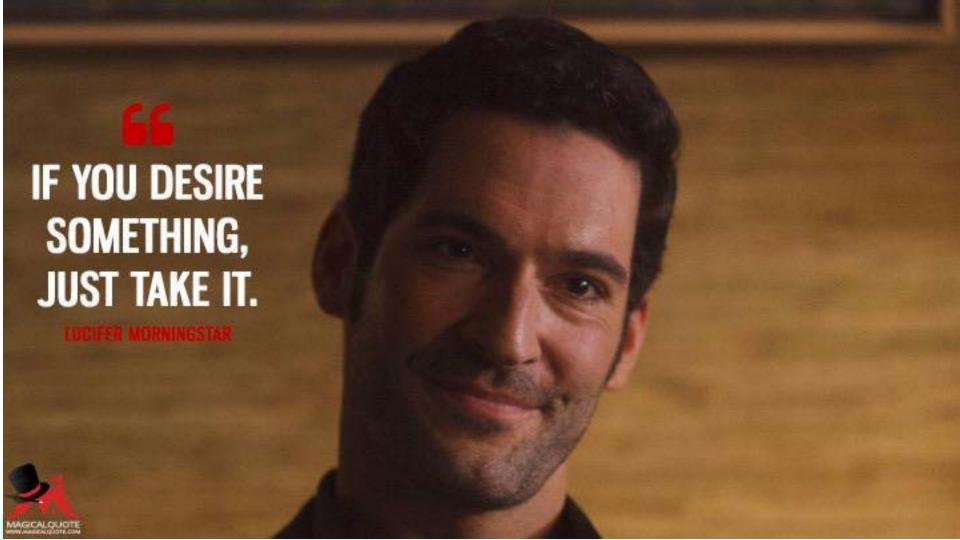


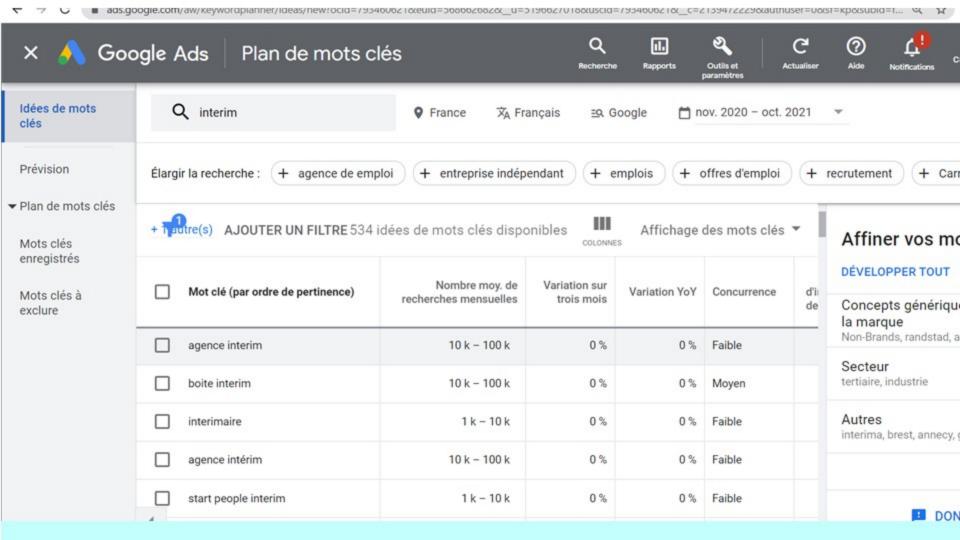
Méthodo et philosophie de projet

FOR CLONDIKE SUPPLIES









Méthodo

- 4000 requêtes pour sélectionner les mots clés et volumes (source Google Ads)
- Nettoyage statistique





Méthodo

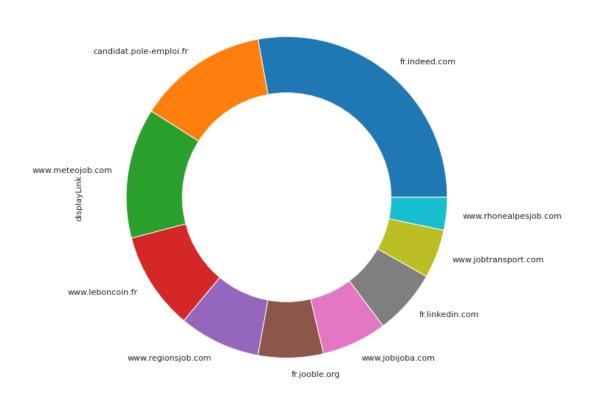
- Scraping des positions Google sur 4000 requêtes
- Scraping de toutes les url => position 100

Modélisations, évaluation et sélection des features



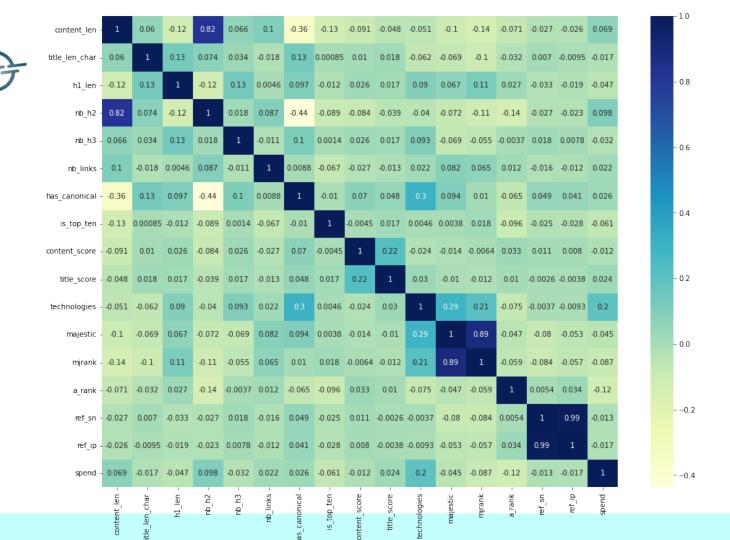
Principaux players

top job boards in France in percentage





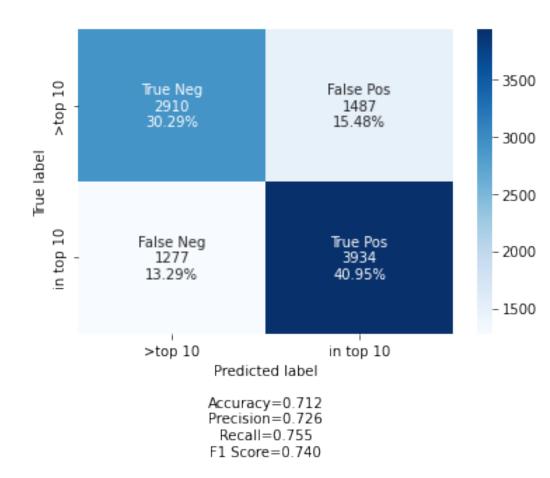
Modélisation(s)





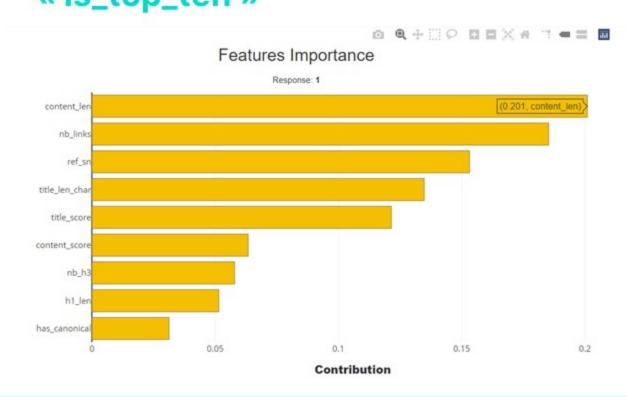
classifier	score	accuracy	recall	f1_score
1 CatBoostClassifier()	0,72	0,72	0,76	0,74
2 LGBMClassifier()	0,72	0,72	0,75	0,74
3 GradientBoostingClassifier()	0,71	0,71	0,75	0,74
4 XGBClassifier()	0,71	0,71	0,74	0,73
5 AdaBoostClassifier()	0,70	0,70	0,73	0,72
6 RandomForestClassifier()	0,69	0,69	0,73	0,72
7 ExtraTreesClassifier()	0,69	0,69	0,73	0,72
8 DecisionTreeClassifier()	0,64	0,64	0,68	0,67
9 LogisticRegression()	0,63	0,63	0,76	0,69

Résultats





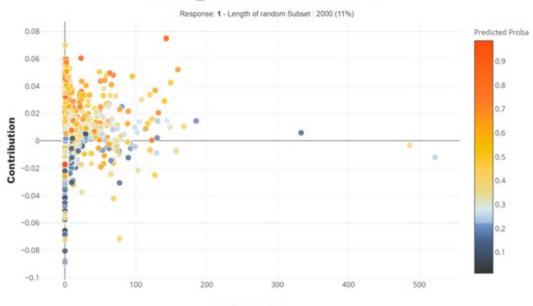
Un problème de classification : « is_top_ten »





Un problème de classification : « is_top_ten »

content_score - Feature Contribution



content score

Next steps

- « industrialisation » du projet : quel que soit le sujet, le marché, le pays
- Amélioration du modèle : page rank, page speed, trust flow, backlinks, balises meta, opengraph, ...
- Optimisation sémantique pour répondre à la question :
 « comment mieux ranker »





in https://www.linkedin.com/in/caroline-heymes

https://people2meet.co

https://github.com/caroheymes?tab=repositories